

Universidad Nacional Autónoma de México

Facultad de Estudios Superiores Acatlán

Diplomado en Ciencia de Datos

Generación 33

Proyecto Final



Detección de uso indebido de credenciales mediante analítica de comportamiento de usuarios y entidades (UEBA)

Presentado a: Raúl López Benítez

Autor: Arellano Ortiz Andre

Fecha: 24 de julio del 2026

Ciudad de México, México

Índice

1. Introducción	3
1.1. La empresa y su propuesta de valor	3
1.2. Flujo de trabajo	4
2. Planteamiento del problema	4
2.1. Decisiones de diseño no negociables	5
3. Estrategia de negocio	5
3.1. Nicho de negocio	5
3.2. Usuarios finales y accionables	6
4. Descripción de los datos	6
4.1. Primer conflicto: la adquisición de los datos	7
4.2. Muestreo justificado	7
4.3. Calidad de los datos	8
5. Análisis exploratorio de datos	8
5.1. El ritmo de la red	8
5.2. Las señales del compromiso	9
5.3. El movimiento lateral hecho visible	9
5.4. El desbalance	10
6. Ingeniería de variables	11
6.1. Nivel (a): qué hizo la cuenta hoy	11
6.2. Nivel (b): la desviación contra su propio pasado	12
6.3. Nivel (c): la desviación contra sus pares	14
6.4. Nivel (d): la novedad del grafo de conexiones	14
6.5. La regla anti-fuga	15
6.6. Etiquetado y partición temporal	16
7. Modelado	16
7.1. Los tres conjuntos	17
7.2. Modelos no supervisados	17
7.3. Segundo conflicto: el agrupamiento degenerado	18
7.4. Modelo supervisado central	18
7.5. Iteración de variables	18
7.6. Selección del mejor modelo y calibración	19
7.7. Evaluación final fuera de tiempo	19

7.8. Reporte de estabilidad	20
7.9. Explicabilidad	21
8. Análisis crítico y conflictos del desarrollo	21
8.1. Tercer conflicto: una autocorrección metodológica	22
8.2. La exploración honesta de mejoras	22
8.3. Contextualización honesta de los resultados	22
9. Resolución del problema	23
9.1. Pipeline de inferencia y puntuación de riesgo	23
9.2. Consumo de modelos: la API	23
9.3. La interfaz de usuario	23
9.4. Asistente conversacional	24
10. Conclusiones	24
10.1. Hallazgos sobre el problema	24
10.2. Hallazgos sobre los datos	24
10.3. Impacto para la toma de decisiones	25
10.4. Justificación del enfoque supervisado	26
10.5. Sobre el rigor metodológico	26
11. Limitaciones y recomendaciones	27
11.1. Limitaciones del trabajo	27
11.2. Recomendaciones y trabajo futuro	27
12. Referencias	28

1. Introducción

El perímetro de seguridad tradicional —firewall, antivirus, sistemas de detección de intrusiones— fue diseñado para detener a un intruso que *rompe* algo. Sin embargo, la mayoría de las brechas modernas no rompen nada: utilizan **credenciales legítimas**, robadas mediante *phishing*, compradas en mercados ilícitos o abusadas por un empleado, para moverse dentro de la red como si fueran un usuario normal. Este es el problema que la industria denomina UEBA (*User and Entity Behavior Analytics*) y que, en la práctica, resulta indistinguible de la amenaza interna: en ambos casos el atacante opera dentro de canales autorizados y cada autenticación individual es, técnicamente, válida.

En este proyecto desarrollé **Nexus Sentinel**, un sistema de puntuación de riesgo que detecta este tipo de comportamiento sobre datos reales de autenticación de una red corporativa. Concebí el proyecto en torno a una premisa que gobernó todas mis decisiones de diseño: *el modelo no debe ver eventos, sino desviaciones*. Una autenticación aislada no dice nada; lo que delata a una cuenta comprometida es la desviación de su patrón de comportamiento habitual. A lo largo del documento narro, el desarrollo completo: desde la adquisición de mil millones de eventos crudos hasta el despliegue de una interfaz funcional en producción, pasando por la ingeniería de variables —que considero el corazón técnico del trabajo— y una evaluación que me esforcé por mantener honesta incluso cuando los resultados no fueron los que esperaba.

La tarea que abordo es de **clasificación binaria supervisada** sobre la unidad de análisis **usuario-día**: dado el resumen del comportamiento de autenticación de un usuario durante un día, el sistema debe estimar la probabilidad de que ese día contenga actividad de compromiso. El problema presenta los retos estructurales que definen a la ciencia de datos aplicada a la ciberseguridad: un desbalance de clases extremo (menos del 0.4 % de los casos son positivos), un volumen masivo de datos (más de mil millones de eventos), datos desidentificados por privacidad y la necesidad de que el resultado sea *explicable*, pues ninguna acción sobre una cuenta o una persona puede tomarse a ciegas.

1.1 La empresa y su propuesta de valor

Nexus Sentinel es la empresa ficticia de analítica de seguridad que constituí para este proyecto. Su producto es precisamente el sistema que documento aquí: una capa de inteligencia que las organizaciones incorporan sobre su infraestructura de seguridad existente para detectar el uso indebido de credenciales legítimas.

El escenario que Nexus Sentinel resuelve es el siguiente. Una empresa cliente sufre un incidente en el que la cuenta de uno de sus ingenieros es utilizada durante semanas para

explorar servidores a los que ese ingeniero jamás accedía. Ninguna alerta se dispara, porque cada autenticación individual es «válida», y el incidente se detecta tarde y de forma casi accidental. Como muestro en la presentación del proyecto, este escenario tiene equivalentes reales y costosísimos en la industria el caso más conocido es el de Target en 2013, donde la credencial robada a un proveedor externo condujo a una brecha de más de 200 millones de dólares.

Ese es el problema que Nexus Sentinel ataca: no vigilar eventos individuales, sino la **desviación del patrón de comportamiento** de cada cuenta. En este documento desarrollo el producto de principio a fin, validándolo sobre datos reales de una red corporativa.

1.2 Flujo de trabajo

El desarrollo comprende siete etapas encadenadas: la adquisición y el muestreo justificado de los datos crudos; un análisis exploratorio orientado a descubrir empíricamente las señales de compromiso; la ingeniería de variables en cuatro niveles de desviación; el modelado supervisado y no supervisado con su evaluación y análisis de estabilidad; la construcción del flujo de inferencia y la puntuación de riesgo; la exposición de los modelos mediante una API; y el desarrollo de una interfaz web con un asistente conversacional.

Cerré cada etapa con una verificación explícita, y varias de ellas revelaron conflictos técnicos y metodológicos que documento con transparencia, pues considero que la forma en que los resolví es parte sustancial del valor del trabajo.

2. Planteamiento del problema

La analítica de comportamiento de usuarios y entidades parte de una observación empírica bien documentada: el uso de credenciales robadas o abusadas es uno de los vectores más frecuentes en las brechas de seguridad modernas. El *Data Breach Investigations Report* de Verizon reporta año con año que el elemento humano y el uso de credenciales comprometidas participan en una fracción mayoritaria de los incidentes analizados [1]. La razón es estructural: robar una credencial es más barato y más silencioso que explotar una vulnerabilidad técnica, y una vez dentro, el atacante hereda todos los permisos legítimos de la cuenta.

El problema técnico central es que las herramientas perimetrales clásicas —SIEM, EDR, firewalls— razonan a nivel de *evento*: una regla se dispara cuando ocurre algo explícitamente prohibido. Pero el uso indebido de credenciales no viola ninguna regla a

nivel de evento: la cuenta tiene permiso para autenticarse. La señal solo existe a nivel de *patrón*: un usuario que de pronto se autentica contra decenas de máquinas que jamás había tocado, en horarios inusuales o mediante protocolos que normalmente no emplea. Detectar esto requiere construir, para cada usuario, una línea base de comportamiento y medir cuánto se desvía de ella cada día.

2.1 Decisiones de diseño no negociables

Antes de escribir una sola línea de código fijé cinco decisiones de diseño que mantuve durante todo el proyecto, precisamente porque son las que separan una solución operativa de un ejercicio académico:

1. **Unidad de análisis = usuario-día.** El riesgo se evalúa sobre el resumen diario del comportamiento de cada usuario, no sobre eventos aislados.
2. **Métricas para desbalance extremo.** Empleo PR-AUC como métrica rectora, recall a una tasa de falsos positivos fija y F1 al umbral operativo. Nunca *accuracy*: con menos del 0.4 % de positivos, un clasificador que prediga siempre «normal» acierta el 99.6 % de las veces siendo completamente inútil. La literatura respalda esta elección: la curva de precisión-recall es más informativa que la ROC al evaluar clasificadores binarios sobre conjuntos desbalanceados [9].
3. **Humano en el circuito.** El sistema prioriza y explica; ninguna acción sobre una cuenta o una persona es automática. La decisión final siempre es de un analista.
4. **Umbrales calibrados por capacidad operativa.** Los umbrales de alerta se fijan por percentiles que producen un número de tickets diarios revisable por el equipo de seguridad, no mediante números arbitrarios.
5. **Muestreo documentado, no oculto.** El volumen masivo se gestiona con un muestreo justificado y trazable, jamás escondiendo la reducción de datos.

3. Estrategia de negocio

3.1 Nicho de negocio

Posicioné a Nexus Sentinel como una capa de **UEBA / Human Risk Analytics**: inteligencia interna para el área de ciberseguridad. La propuesta no compite con el SIEM ni con el EDR, sino que consume sus registros y devuelve una priorización explicada. La propuesta de valor es medible: reducir el volumen de alertas que un analista debe revisar manualmente, manteniendo el *recall* sobre los compromisos reales. En otras pa-

labras, convertir un pajar de mil millones de eventos en una lista corta, priorizada y justificada de casos investigables.

3.2 Usuarios finales y accionables

Diseñé el sistema para tres perfiles de usuario, con el analista de un Centro de Operaciones de Seguridad (SOC) como usuario principal:

- **Analista SOC (principal):** necesita una cola priorizada y explicada, no un mar de alertas. El sistema le entrega el triaje por riesgo, la explicación de cada caso y las acciones de decisión.
- **CISO (secundario):** necesita la tendencia de riesgo organizacional y evidencia para justificar inversión. Le entrega un panel ejecutivo con el riesgo agregado y la eficiencia del SOC.
- **Oficial de Cumplimiento (implícito):** necesita auditabilidad de las decisiones sobre cuentas. Le entrega la trazabilidad completa desde las variables hasta la decisión humana registrada.

Traduje la puntuación de riesgo (0–100) a tres niveles accionables mediante un semáforo, cuya correspondencia con las acciones del SOC es uno a uno: **verde** (registro pasivo que alimenta la línea base del usuario), **naranja** (ticket con la evidencia y su explicación, para revisión) y **rojo** (investigación prioritaria con validación humana obligatoria antes de cualquier acción sobre la cuenta).

4. Descripción de los datos

Trabajé con el conjunto de datos *Comprehensive, Multi-Source Cyber-Security Events*, publicado por el Laboratorio Nacional de Los Álamos (LANL) y liberado por su autor para investigación pública [2, 3]. Es un conjunto de datos **reales**: 58 días consecutivos de eventos desidentificados de la red corporativa interna de LANL, con eventos de un equipo de *red team* (ataques reales controlados) que sirven como *ground truth* de comportamiento malicioso. En total, el conjunto documenta 1 648 275 307 eventos de 12 425 usuarios y 17 684 computadoras.

Utilicé dos de sus archivos: `auth.txt.gz` (7.2 GB comprimidos, aproximadamente 1 051 millones de autenticaciones Windows/Active Directory), que es la fuente principal, y `redteam.txt.gz` (4.8 KB), que contiene los eventos de compromiso que uso como etiquetas. Elegí esta fuente precisamente porque su desbalance extremo, su volumen masivo y su desidentificación reproducen las condiciones exactas que un científico de datos enfrenta en un SOC real. Cabe destacar que la guía de la rúbrica veta explícita-

mente a Kaggle como fuente de datos; LANL es una fuente institucional primaria y de acceso directo, lo que la hace idónea.

4.1 Primer conflicto: la adquisición de los datos

El primer obstáculo real del proyecto apareció en la adquisición. La documentación y los trabajos previos sobre este conjunto asumen una descarga directa y anónima desde el portal de LANL. Sin embargo, al momento de desarrollar el proyecto el portal había incorporado un *data fence*: un formulario que exige un correo electrónico y una declaración de uso, y que a cambio devuelve un *token* temporal con el que se construye la URL de descarga. Tuve que adaptar mi módulo de adquisición para solicitar ese token programáticamente antes de poder descargar los archivos, y documenté la fecha, la URL y el tamaño de cada descarga para garantizar la reproducibilidad.

El segundo obstáculo fue el volumen. Descargar 7.2 GB comprimidos y, sobre todo, procesarlos, exigía una estrategia cuidadosa: implementé la descarga en *streaming* con reanudación automática —que efectivamente tuvo que reanudarse tras una interrupción a mitad de la transferencia— y la lectura del archivo comprimido por bloques (*chunks*), sin descomprimirlo nunca por completo a disco. Esta decisión de ingeniería fue la que hizo viable el resto del proyecto en un equipo de cómputo personal.

4.2 Muestreo justificado

Mil millones de eventos ni caben cómodamente en memoria ni son necesarios. Gestioné el volumen con un muestreo que documenté por completo, en lugar de ocultarlo. Las reglas y su justificación fueron:

- **Ventana temporal:** los primeros 30 días. Verifiqué empíricamente sobre el archivo completo de 58 días que el 100 % de los eventos del *red team* ocurre entre los días 1 y 29, de modo que la ventana conserva la totalidad del *ground truth*.
- **Usuarios:** incluí las 104 cuentas comprometidas más una muestra aleatoria de 4 000 usuarios normales, estratificada por cuartil de actividad y con semilla fija, para no sesgar la línea base hacia cuentas hiperactivas ni casi inactivas.
- **Exclusión de cuentas no humanas:** excluí del universo muestreable las cuentas de máquina (terminadas en \$) y de sistema (SYSTEM, Local Service, entre otras), pues el scoring debe recaer sobre personas.

El resultado fue una muestra de 37 580 871 eventos para 4 104 usuarios, que persistí en formato Parquet (aproximadamente 209 MB) como el conjunto de trabajo reproducible

del resto del proyecto.

4.3 Calidad de los datos

Documenté las particularidades de calidad de esta fuente real. El campo `auth_type` está ausente (marcado con «?») en el 60.2 % de los eventos, y `logon_type` en el 18.7 %. En lugar de descartar o imputar a ciegas, traté el valor nulo como información en sí mismo, pues su patrón no es aleatorio sino que depende del mecanismo de recolección de cada evento. A si mismo, el archivo de *red team* contiene 749 líneas de las cuales 12 líneas distintas aparecen duplicadas (34 filas en exceso); las deduplico a 715 eventos únicos, correspondientes a 104 cuentas. Como verificación adicional a nivel de evento, confirmé que 702 de esos 715 eventos tienen su línea de autenticación exacta en la muestra, y que de esos 702, **701 fueron autenticaciones exitosas y solo 1 fue un fallo**. Este dato es una confirmación directa de la tesis del proyecto: el atacante con credenciales robadas no rompe puertas, las abre.

5. Análisis exploratorio de datos

El objetivo de mi análisis exploratorio fue triple: caracterizar el comportamiento normal de autenticación, cuantificar el desbalance real y descubrir empíricamente las señales de compromiso que después convertiría en variables. Adopté un criterio deliberado de presentación: pocas figuras, cada una respondiendo una pregunta concreta del problema, en lugar de saturar el documento con gráficas sin valor analítico.

5.1 El ritmo de la red

Los tiempos del conjunto son anónimos: son una época que arranca en 1, sin fecha real, por seguridad. Mi primera pregunta fue si podía recuperar el ritmo humano de la red únicamente a partir de la periodicidad de los datos. La Figura 1 muestra que sí. Al agregar los eventos de origen humano por hora relativa del día (el residuo de dividir el tiempo entre 86 400 segundos), emerge un ciclo circadiano claro con un horario laboral inferido de 7:00 a 16:00. Un matiz metodológico relevante: existe una base de automatización que corre 24/7 bajo cuentas de usuario —el valle nocturno conserva cerca del 59 % de la actividad del pico— por lo que definí la frontera de «horario laboral» como el punto medio entre el valle y el pico, y no como un porcentaje del pico. La serie diaria, además, revela los fines de semana sin necesidad de un calendario: aparecen como caídas de dos días con periodicidad siete. El *red team* ataca en 18 de los 30 días.




Figura 1: Ritmo de la red inferido del tiempo anónimo. Izquierda: ciclo circadiano y horario laboral inferido (zonas grises = fuera de horario). Derecha: serie diaria con fines de semana sombreados y días con ataque marcados en rojo.

5.2 Las señales del compromiso

Comparé los 181 usuario-días comprometidos contra los 47 775 normales sobre tres señales candidatas (Figura 2). El hallazgo central, y la señal más citada en la literatura sobre este conjunto, es el **alcance**: la mediana de computadoras destino distintas es de 22 en los días comprometidos frente a 10 en los normales —la huella del movimiento lateral. El segundo hallazgo fue contraintuitivo y resultó valioso: el compromiso **no** se parece a un ataque de fuerza bruta. Los días comprometidos presentan fallos con más frecuencia (50 % de los días frente a 24 %) pero en proporción mínima (un ratio típico de 0.003), porque quien usa credenciales válidas robadas avanza con éxito. De hecho, el fallo masivo pertenece a la población normal: el 17 % de los usuario-días normales son 100 % fallos, la firma de la automatización con credenciales caducas. Finalmente, el protocolo NTLM —asociado en la literatura a técnicas de movimiento lateral tipo *pass-the-hash*, catalogadas por el marco MITRE ATT&CK [11]— aparece con una mediana de ratio de 0.02 en los comprometidos frente a 0 en los normales.

5.3 El movimiento lateral hecho visible

Para darle una cara concreta al movimiento lateral, construí el grafo de conexiones usuario→computadora de una cuenta comprometida, antes y durante el ataque (Figura 3). En sus ocho días de historia previa, la cuenta acumuló 27 destinos distintos; el día del ataque tocó 49, de los cuales 28 eran nuevos —su grafo se expandió más en un solo día que en toda su historia previa— y 11 de esos destinos nuevos están confirmados en el *ground truth*. Ninguna de esas autenticaciones falló ni disparó una alerta tradicional: la anomalía solo existe a nivel del patrón.




Figura 2: Comparación normal vs. comprometido sobre tres señales. El panel de destinos distintos hace visible el movimiento lateral; el de fallos revela que el compromiso usa credenciales válidas; el de NTLM confirma el protocolo legado como señal.




Figura 3: Grafo ego de una cuenta comprometida. En gris, los destinos que la cuenta ya conocía; en rojo, los que tocó por primera vez el día del ataque. El movimiento lateral es la novedad de conexiones.

5.4 El desbalance

No presento el desbalance como una gráfica sino como un indicador, porque un número tan extremo se comunica mejor así: de los 47 956 usuario-días de la muestra, solo 181 contienen actividad maliciosa (el 0.38 %, es decir, uno de cada 265), y esto en una muestra deliberadamente enriquecida con la totalidad de las cuentas comprometidas —la población real es del orden de 50 veces más desbalanceada. Este único dato es el argumento definitivo contra el uso de la exactitud como métrica y la justificación de todas las decisiones de evaluación que tomé después.

6. Ingeniería de variables

Considero esta la sección crítica del proyecto. Un evento de autenticación aislado no dice nada —el incidente que motiva todo este trabajo ocurre precisamente porque cada autenticación individual es válida—. Lo que convierte 37.6 millones de eventos en algo modelable es responder, para cada usuario y cada día, cuatro preguntas encadenadas. Mi principio rector fue que ninguna variable existiera por estar disponible, sino porque responde una pregunta de desviación concreta.

Las organicé en cuatro niveles, y cada nivel existe porque el anterior deja un punto ciego que un atacante disciplinado podría explotar. El cuadro 1 resume esa progresión.

Nivel	La pregunta	El punto ciego que cierra
(a) Crudas	¿Qué hizo hoy?	Sin esto no hay nada que comparar
(b) Desviación personal	¿Qué tan distinto de su pasado?	22 destinos son rutina para un administrador y alarma para un contador: lo normal es personal
(c) Desviación grupal	¿Qué tan distinto de sus pares hoy?	Un evento global legítimo, como una actualización masiva, dispara a todos a la vez
(d) Novedad de grafo	¿Qué tan nuevo es su grafo de conexiones?	El atacante disciplinado mantiene volumen y horario normales, pero no puede evitar tocar máquinas que la cuenta jamás visitó

Cuadro 1: Los cuatro niveles de la ingeniería de variables. Cada nivel responde una pregunta que el anterior no puede responder.

El resultado es una tabla maestra de **47 956 usuario-días descritos por 61 variables**, sin un solo valor faltante ni infinito. Las imputaciones que realicé son explícitas y documentadas, no accidentales: desviaciones a cero cuando el historial disponible es menor a siete días, y grupo -1 para usuarios sin perfil en el conjunto de entrenamiento. En ambos casos acompaño la imputación con una bandera booleana, de modo que el modelo pueda aprender a desconfiar de un valor imputado en lugar de leerlo como si fuera una medición real.

6.1 Nivel (a): qué hizo la cuenta hoy

Cada familia de variables crudas captura una táctica concreta del adversario:

- **Volumen** (eventos, logones): actividad automatizada corriendo bajo una cuenta humana.
- **Alcance** (computadoras destino y origen distintas): la huella del movimiento lateral que el análisis exploratorio confirmó.

- **Fallos**, incluida la ráfaga máxima de fallos consecutivos, firma de fuerza bruta. El fallo crudo engaña por sí solo, y por eso esta familia únicamente resulta útil combinada con el nivel siguiente.
- **Protocolo**: NTLM como vehículo de *pass-the-hash*, el desbalance entre tickets TGS y TGT como señal de abuso de Kerberos, y el propio valor ausente contado como información.
- **Tipo de sesión**: en una red donde las sesiones interactivas son el 0.2 % del total, una sesión inusual dice mucho.
- **Temporales**: construidas con las fronteras de horario laboral y días no laborales que inferí de los propios datos, no con un calendario externo.
- **Dirección**: cuántas veces la cuenta aparece como identidad *destino* de otra, que es la firma de una credencial inyectada en cadenas de saltos.

Antes de avanzar quise entender con qué tipo de distribuciones estaba tratando. El cuadro 2 muestra las estadísticas de nueve variables representativas.

Variable	Media	Mediana	Máximo
Eventos de autenticación	773.62	287.0	243 541
Computadoras destino	10.07	10.0	2 343
Fallos	4.70	0.0	11 434
Ráfaga máxima de fallos consecutivos	3.96	0.0	10 405
Proporción de NTLM	0.03	0.0	1.0
Tickets TGS	91.10	42.0	28 221
Eventos fuera de horario	372.51	86.0	112 286
Amplitud horaria (horas activas)	13.38	15.0	23
Uso como identidad destino	10.12	0.0	17 229

Cuadro 2: Estadísticas de las variables crudas sobre los 47 956 usuario-días. Las medias superan ampliamente a las medianas en todas las familias: las distribuciones tienen colas extremas.

Estas cifras confirman el punto ciego del nivel (a). Con colas tan largas, cualquier umbral global sobre una variable cruda cometería los dos errores a la vez: ahogaría al equipo de seguridad en falsos positivos de cuentas naturalmente ruidosas y, simultáneamente, dejaría pasar a un atacante discreto operando dentro de una cuenta silenciosa. La salida no es buscar un umbral mejor, sino cambiar la pregunta y comparar a cada usuario contra sí mismo.

6.2 Nivel (b): la desviación contra su propio pasado

Este nivel resuelve el problema que hace invisible a este tipo de incidente: lo normal es personal. Para cada variable relevante calculo, sobre una ventana móvil de hasta 30

días activos previos del mismo usuario, tres construcciones complementarias:

1. el **z-score** del día respecto a la media y desviación históricas del propio usuario;
2. la **razón contra su máximo histórico**, que detecta récords personales incluso cuando la varianza del usuario es alta y el z-score se diluye;
3. **banderas de primera vez**, porque hay comportamientos en los que pasar de cero a uno importa más que cualquier magnitud.

Aquí vive la regla anti-fuga central del proyecto, que detallo en la sección 6.5: todas las estadísticas se calculan sobre la serie del usuario desplazada un día, de modo que el día evaluado nunca participa en el cálculo de su propia línea base. Sin ese desplazamiento, un día de actividad masiva elevaría su propia media y quedaría auto-camouflado.

Para mostrar qué logra este nivel, el cuadro 3 traduce a variables el mismo día de ataque que analicé en el análisis exploratorio.

Variable (cuenta U3635, día 8)	Valor
Eventos de autenticación	761.00
Desviación de volumen frente a su base	0.687
Computadoras destino	49.00
Desviación de alcance frente a su base	7.694
Razón contra su máximo histórico de alcance	1.885
Desviación de alcance frente a sus pares	4.548
Conexiones nuevas abiertas	28.00
Fracción de conexiones nuevas	0.571
Rareza media de los destinos	0.378

Cuadro 3: El día del ataque de una cuenta comprometida, traducido a variables. El volumen es indistinguible de lo normal; el alcance y la novedad lo delatan.

Esta fila condensa la tesis del proyecto. El día del ataque **el volumen parece normal**: la desviación de eventos es de 0.687, menos de una desviación estándar de su propia media, de modo que un detector basado en volumen no habría visto absolutamente nada. Pero las desviaciones de alcance y novedad lo delatan por completo: tocó destinos a **7.7 desviaciones estándar** de su línea base personal, rompió su máximo histórico por un 88 %, quedó a **4.5 desviaciones** de sus pares conductuales ese mismo día, y 28 de sus 49 destinos eran nuevos, con una rareza media ocho veces superior a la mediana normal. Es exactamente la narrativa que la interfaz traduce después a lenguaje natural para el analista: *hoy tocó 49 servidores; su historia decía otra cosa*.

6.3 Nivel (c): la desviación contra sus pares

La desviación personal tiene a su vez dos puntos ciegos. El primero son los usuarios con poco historial, que sencillamente no tienen contra qué compararse. El segundo, más sutil, son los eventos globales legítimos: si una actualización masiva dispara la actividad de toda la organización un martes, castigar a cada usuario por su z-score personal generaría una ola de falsos positivos. La comparación contra pares resuelve ambos, bajo una lógica simple: si todos los de tu rol subieron hoy, tú no destacas.

El obstáculo es que los datos están desidentificados y no existe organigrama ni catálogo de puestos. Construyo entonces los pares **por comportamiento**, agrupando a los usuarios según su perfil mediano del periodo de entrenamiento y midiendo la desviación de cada día contra la distribución de su grupo. La construcción del agrupamiento y el conflicto metodológico que tuve que corregir se detallan en la sección de modelado, porque este mismo modelo cumple allí un segundo papel como detector no supervisado.

La partición resultante separa dos regímenes conductuales nítidos: un grupo de 2332 cuentas ligeras e intermitentes —mediana de 6 eventos y 2 destinos por día, sin actividad fuera de horario— y otro de 1375 cuentas pesadas siempre encendidas, con mediana de 406 eventos, 12 destinos y 23 horas de amplitud. Los 397 usuarios restantes carecen de días en entrenamiento, reciben grupo -1 y su desviación grupal se imputa a cero con su bandera correspondiente.

Que los grupos separen precisamente los dos regímenes que contaminaban las variables crudas —las cuentas ruidosas frente a las silenciosas— es lo que vuelve útil este nivel. Y la evidencia confirma que funciona: la mediana de la desviación de alcance contra pares es de **0.66 en días comprometidos frente a $-0,16$ en días normales**.

6.4 Nivel (d): la novedad del grafo de conexiones

Queda un último punto ciego, y es el más peligroso: el atacante disciplinado que mantiene volumen normal, respeta el horario laboral, no genera fallos y usa protocolo limpio. Lo único que ese adversario no puede evitar es tocar máquinas que la cuenta jamás visitó, porque el movimiento lateral es, por definición, novedad de conexiones.

Sobre un grafo bipartito acumulado usuario $\rightarrow$ computadora calculo cuatro variables: cuántas **aristas nuevas** abre el día; qué **fracción** de su actividad representan, que distingue «un servidor nuevo» de «casi todo lo de hoy es nuevo»; la **rareza media** de los destinos, ponderando cada uno por lo poco que lo visita el resto de la organización; y cuántas **máquinas origen nuevas** utiliza, que es la otra cara del movimiento lateral.

La regla anti-fuga es aquí especialmente estricta: el grafo de referencia se congela al final

del día anterior, y la implementación calcula las variables del día *antes* de incorporar sus propios eventos al estado acumulado. Además, el primer día activo de cada usuario se neutraliza a cero, porque de otro modo todo sería nuevo por construcción y no por conducta.

Variable (mediana)	Día normal	Día comprometido
Conexiones nuevas abiertas	0.000	1.000
Fracción de conexiones nuevas	0.000	0.068
Rareza media de los destinos	0.044	0.133
Máquinas origen nuevas	0.000	2.000
Uso como identidad destino	0.000	20.000

Cuadro 4: Separación de clases de las variables de novedad de grafo. Todas discriminan en mediana, y la última lo hace de forma inesperadamente marcada.

El cuadro 4 muestra que las cuatro variables separan las clases en mediana y de forma muy limpia. El usuario-día normal **no abre conexiones nuevas** —la rutina es rutina—, mientras que el día comprometido abre una o más, se autentica desde dos máquinas origen nuevas y triplica la rareza media de sus destinos.

La sorpresa está en la última fila. Durante el ataque, la credencial aparece como identidad destino de otras identidades unas veinte veces por día, cuando lo normal es que eso no ocurra nunca: es la firma de las cadenas de salto del *red team*. Añadí esta variable casi por completitud, y resultó de las más discriminantes de todo el conjunto.

6.5 La regla anti-fuga

El error metodológico más probable y costoso en un proyecto con partición temporal y variables históricas es la **fuga de información** del futuro hacia el pasado. Es además un error silencioso: no produce ningún fallo visible, sino métricas excelentes que se desmoronan en producción. Lo traté como una prioridad de primer orden y establecí cuatro reglas estrictas:

1. toda estadística histórica de la desviación personal se calcula desplazando la serie del usuario un día, excluyendo el día evaluado de su propia línea base;
2. el grafo de referencia de la novedad se congela al día anterior antes de evaluar cada día;
3. el modelo de pares se ajusta únicamente con días del conjunto de entrenamiento, de modo que la definición misma de «sus pares» no conoce el futuro;
4. ninguna variable deriva, directa o indirectamente, del archivo de etiquetas.

Estas reglas no las di por supuestas: las verifiqué explícitamente, línea por línea, me-

diante una auditoría dedicada del código. La cuarta merece un matiz, porque conservo el conteo de eventos del *red team* por usuario-día para análisis de severidad, pero deliberadamente **fuera** de la lista de variables que consume el modelo. Guardar un dato y permitir que el modelo lo lea son dos decisiones distintas, y confundirlas equivale a entrenar con la respuesta.

6.6 Etiquetado y partición temporal

Etiqueté cada usuario-día con $y = 1$ si contiene al menos un evento del *red team*. La verificación relevante aquí es la **cobertura**: que cada par (usuario, día) del *ground truth* tenga su fila correspondiente en la tabla maestra, porque un par perdido sería un ataque invisible para el entrenamiento. La cobertura resultó perfecta: los **181 pares** del *ground truth* tienen su fila, sin excepciones. El desbalance queda entonces en 181 de 47 956 usuario-días, es decir un 0.38 %, aproximadamente uno de cada 265. Este número no es un dato ornamental: gobierna directamente el parámetro de re-peso del modelo supervisado y la elección de las métricas de evaluación.

La partición es **temporal estricta**, nunca aleatoria. Descarté el *k-fold* aleatorio por dos razones independientes: los días de un mismo usuario están autocorrelacionados, de modo que el modelo aprendería a reconocer usuarios en lugar de generalizar comportamiento; y las variables históricas de un día de prueba construido con días de entrenamiento mezclados filtrarían información del futuro. Corto en cambio por día calendario, simulando el despliegue real: entrenar con el pasado y puntuar el futuro.

Verifiqué además que ambos lados de la partición contuvieran días de ataque, porque sin positivos en prueba no habría nada que evaluar. El corte inicial en el día 20 deja 147 usuario-días maliciosos del lado de entrenamiento y 34 del lado de prueba, con desbalances comparables de 0.48 % y 0.19 % respectivamente. En la etapa de modelado refino este corte binario en tres conjuntos, separando los últimos días del entrenamiento como validación, según se detalla en el cuadro 5.

7. Modelado

Adopté un enfoque híbrido que combina un modelo no supervisado como línea base con un modelo supervisado como componente central, más un modelo de agrupamiento con doble propósito.

7.1 Los tres conjuntos

Refiné la partición temporal en tres conjuntos cronológicamente disjuntos: entrenamiento (días 0–13, con 120 positivos), validación (días 14–19, con 27 positivos) y prueba fuera de tiempo (días 20–29, con 34 positivos). El corte de validación no fue arbitrario: lo elegí con los datos, tras verificar que un corte en el día 16 dejaría la validación sin un solo positivo. Todo lo que requiere decidir —hiperparámetros, calibrador, modelo ganador y umbrales— lo decidí en validación; el conjunto de prueba lo reservé para una única evaluación final. El cuadro 5 resume la partición.

Conjunto	Días	Usuario-días	% del total	Positivos
Entrenamiento	0–13	22 308	46.5 %	120
Validación	14–19	8 147	17.0 %	27
Prueba (fuera de tiempo)	20–29	17 501	36.5 %	34
Total	0–29	47 956	100 %	181

Cuadro 5: Partición temporal en tres conjuntos cronológicamente disjuntos. Las proporciones no son un porcentaje elegido de antemano: al cortar por día calendario, las dicta el volumen de actividad de cada día y la restricción de que la validación contenga positivos suficientes para medir PR-AUC.

7.2 Modelos no supervisados

Como línea base empleé un **Isolation Forest** [4], que aísla anomalías mediante particiones aleatorias del espacio. Lo entrené sin etiquetas y solo con datos de entrenamiento, y lo evalué a posteriori contra las etiquetas. Tomé una decisión que quiero justificar explícitamente: mantuve el parámetro de contaminación en su modo automático en lugar de fijarlo con la tasa real de ataque, porque fijarlo con esa tasa sería filtrar información de las etiquetas a un modelo que se presume no supervisado. Su desempeño fue el esperado para una línea base: un PR-AUC de 0.027, útil como piso de referencia pero insuficiente como detector único.

El segundo modelo no supervisado fue un **K-Means** [7] sobre el perfil de cada usuario, con el número de grupos elegido por el coeficiente de silueta [8]. Este modelo cumple un doble propósito: genera las variables de desviación grupal del nivel (c) y, como puntuación de anomalía por distancia al centroide del rol del usuario, alcanza un PR-AUC de 0.093, superando a la línea base de Isolation Forest con un modelo mucho más simple.

7.3 Segundo conflicto: el agrupamiento degenerado

La primera ejecución del K-Means produjo una solución degenerada que documento como un conflicto real: el criterio de silueta seleccionó $k = 2$ con un grupo de **un solo usuario** y una silueta engañosamente alta de 0.997. Una cuenta atípica extrema secuestraba el agrupamiento, y un grupo unipersonal no es un grupo de pares (no hay nadie contra quién compararse). Lo corregí con dos salvaguardas: una transformación logarítmica sobre las variables de volumen antes del escalado, y la regla de que un k solo es candidato si su grupo más pequeño agrupa al menos el 1 % de los usuarios. Con ello obtuve una solución sana de $k = 2$ (silueta 0.63) con dos roles conductuales interpretables: «cuentas ligeras e intermitentes» y «cuentas pesadas siempre encendidas». Documento este episodio porque es exactamente el tipo de decisión que separa un agrupamiento decorativo de uno útil.

7.4 Modelo supervisado central

El modelo central es **XGBoost** [5], una implementación escalable de *gradient boosting* sobre árboles. Manejé el desbalance con el parámetro `scale_pos_weight` fijado en 184.9 —el cociente de negativos sobre positivos del conjunto de entrenamiento, no de la tabla completa. El número de árboles no lo fijé como hiperparámetro sino que resultó de una detención temprana por el PR-AUC de validación (el modelo ganador se detuvo en 62 árboles). Realicé una búsqueda aleatoria de 40 configuraciones sobre siete hiperparámetros, evaluadas sobre la validación temporal y nunca sobre un *k-fold* aleatorio. La configuración ganadora es deliberadamente pequeña y regularizada (profundidad máxima 3, tasa de aprendizaje $\approx 0,10$, peso mínimo por hoja ≈ 17), lo cual tiene todo el sentido con solo 120 positivos de entrenamiento. Como referencias comparativas entrené también un Random Forest y una Regresión Logística.

7.5 Iteración de variables

Tras el primer modelo cumplí la iteración obligatoria sobre la ingeniería de variables: probé agregar la distancia al centroide del K-Means como una variable adicional del modelo supervisado. La **rechacé** con base en los datos, pues el PR-AUC de validación fue ligeramente inferior con ella (0.2227) que sin ella (0.2264): la información que aportaba ya estaba capturada por las variables de desviación grupal. Documento la prueba y la decisión negativa porque un «no mejoró, no se queda» respaldado por números vale más que acumular variables por inercia.

7.6 Selección del mejor modelo y calibración

Seleccioné el modelo en validación, con el PR-AUC como criterio rector. XGBoost ganó por más del doble sobre las referencias, como muestra la Tabla 6. La ventaja del *boosting* con re-pesado del gradiente sobre el promediado de árboles del Random Forest, y sobre la incapacidad de la regresión lineal para capturar interacciones (como «NTLM alto y destinos nuevos»), quedó cuantificada.

Modelo	PR-AUC (val)	Recall @ FPR = 1 % (val)
XGBoost (central)	0.226	0.63
Random Forest	0.107	0.37
Regresión Logística	0.085	0.33

Cuadro 6: Selección del mejor modelo en el conjunto de validación. XGBoost domina bajo la métrica rectora y bajo el criterio de desempate.

La salida cruda de un XGBoost re-pesado no es una probabilidad interpretable, sino un valor inflado por diseño. Como la puntuación de riesgo final y los umbrales del SOC se construyen sobre ella, la **calibré** —ajustando el calibrador únicamente con validación. No elegí el método por dogma: comparé la calibración isotónica contra la de Platt mediante el *Brier score* en validación cruzada interna, y ganó la isotónica por un margen mínimo (0.00294 frente a 0.00299), lo que respaldó empíricamente la elección.

7.7 Evaluación final fuera de tiempo

Con todas las decisiones ya tomadas, evalué una única vez sobre el conjunto de prueba fuera de tiempo. La Tabla 7 y la Figura 4 resumen los resultados. El PR-AUC de prueba fue de 0.056: una caída real respecto al 0.226 de validación, cuyas causas son identificables —solo 34 positivos en prueba y campañas de ataque distintas a las de entrenamiento. Reporto también el ROC-AUC de 0.939, pero con la advertencia explícita de que, con un 0.19 % de positivos, un ROC-AUC alto es engañosamente cómodo: el 99.8 % de los pares que compara son triviales. La curva de precisión-recall del panel izquierdo cuenta la historia verdadera.

El panel derecho de la Figura 4 es, en mi opinión, la herramienta más valiosa para el negocio, pues traduce el desempeño estadístico en lenguaje operativo: con un presupuesto de 20 alertas diarias, el sistema cubre el 31 % de las cuentas comprometidas del periodo; con 100 alertas diarias, el 85 %. Esta curva convierte la pregunta «¿qué tan bueno es el modelo?» en «¿cuántos analistas cuesta cada punto de recall?».

Métrica (prueba fuera de tiempo)	Modelo calibrado	Isolation Forest
PR-AUC	0.056	0.027
ROC-AUC (con advertencia)	0.939	0.759
Recall @ FPR = 1 %	0.34	0.12
Recall @ FPR = 0.1 %	0.10	0.09

Cuadro 7: Evaluación final sobre el conjunto de prueba fuera de tiempo (días 20–29). La tasa base de positivos es del 0.19 %.




Figura 4: Izquierda: curva precisión-recall en prueba (la línea punteada es el azar). Derecha: el puente entre el modelo y el negocio —recall de cuentas comprometidas en función del presupuesto de alertas por día.

7.8 Reporte de estabilidad

Un modelo que discrimina pero se desestabiliza entre periodos no es desplegable. Por ello incluí un reporte de estabilidad sobre el periodo fuera de tiempo, con los indicadores estándar de la industria del riesgo [10]. El **PSI** (*Population Stability Index*) de la puntuación entre entrenamiento y prueba fue de 0.019, dentro del rango «estable»: la distribución de scores que vería el SOC apenas se movió entre periodos. El estadístico **KS** de clasificación fue de 0.74, indicando una separación fuerte entre las poblaciones de positivos y negativos. El **CSI** (*Characteristic Stability Index*) de las variables reveló que dos de ellas —las desviaciones de fallos y de NTLM respecto a los pares— sí derivan entre periodos, lo cual no es un defecto del *pipeline* sino un hecho del fenómeno: ambas dependen de *cómo* ataca el *red team* en cada campaña, que cambia. El resto de las variables, incluidas todas las de grafo, permanecen estables, y el *score* agregado se mantiene estable pese a la deriva de esas dos entradas.

7.9 Explicabilidad

Cumpliendo el principio de diseño de que ninguna puntuación viaje sin su explicación, empleé valores SHAP [6] para interpretar el modelo. El resumen global (Figura 5) confirma que las señales dominantes son el ratio de NTLM, el número de máquinas origen nuevas y la rareza media de los destinos —es decir, protocolo anómalo y novedad de grafo, no volumen crudo. El modelo aprendió la tesis del proyecto, no un atajo. Esta misma técnica, en su versión local por usuario-día, es la que alimenta la explicación que el analista ve en la interfaz.




Figura 5: Resumen global de valores SHAP sobre el conjunto de prueba. Dominan las variables de protocolo y de novedad de conexiones, validando el diseño multinivel de la ingeniería de variables.

8. Análisis crítico y conflictos del desarrollo

Considero que la honestidad sobre las limitaciones es parte del rigor científico, por lo que dedico una sección al análisis crítico de los resultados y a los conflictos que enfrenté, más allá de los ya narrados en la adquisición de datos y el agrupamiento degenerado.

8.1 Tercer conflicto: una autocorrección metodológica

Antes de aceptar los resultados como definitivos, exploré tres palancas para mejorarlos, y durante esa exploración cometí —y corregí— un error metodológico que documento precisamente porque su corrección es evidencia de rigor. Al probar la agregación del riesgo a nivel de cuenta (tomar el máximo de los últimos K días), inicialmente elegí $K = 7$ porque era el valor que mejor se veía *en el conjunto de prueba*, obteniendo un PR-AUC aparentemente superior de 0.084. Esto es exactamente la fuga metodológica que había estado combatiendo durante todo el proyecto: elegir un hiperparámetro mirando el conjunto de prueba. Lo detecté, rehízo la selección eligiendo K correctamente sobre la validación —que resultó en $K = 1$, es decir, sin agregación— y el «resultado» de mejora se desvaneció.

8.2 La exploración honesta de mejoras

Probé tres palancas y ninguna sobrevivió a una selección honesta: (1) extender la ventana temporal no añade positivos, pues verifiqué que no existen ataques fuera de los días 1–29 en el conjunto completo; (2) combinar las puntuaciones de XGBoost y K-Means no generaliza, pues el peso óptimo en validación no transfiere a prueba; y (3) la agregación por cuenta, correctamente evaluada, no mejora. Esto no es un fracaso del *pipeline*: con solo 181 eventos de compromiso en todo el conjunto, no hay margen estadístico para que el ajuste fino encuentre algo que generalice, y el techo de esta fuente de datos con este enfoque ya se alcanzó.

8.3 Contextualización honesta de los resultados

Los resultados son modestos en términos absolutos pero defendibles como primera iteración de un problema genuinamente difícil. Un análisis de *bootstrap* sobre los 34 positivos de prueba arroja un intervalo de confianza del 95% para el PR-AUC de $[0,022, 0,146]$: amplio por el tamaño de muestra, pero cuyo límite inferior sigue estando cerca de nueve veces por encima de un ordenamiento aleatorio (cuyo PR-AUC medio medí en 0.0025). La afirmación «el modelo discrimina mejor que el azar» es, por tanto, sólida y no frágil. La honestidad exige reconocer también el costo: al umbral operativo naranja, la precisión es baja (13 verdaderos positivos frente a 280 falsos positivos), lo que refleja el reto real de este desbalance. El punto de comparación correcto para juzgar el modelo no es un umbral absoluto de «bueno», sino el *lift* sobre el azar y la estabilidad del ordenamiento, criterios bajo los cuales el sistema cumple.

9. Resolución del problema

La utilidad de un modelo se materializa únicamente cuando es accesible para su usuario final. Dedicué la última parte del proyecto a convertir los modelos entrenados en un sistema operativo completo.

9.1 Pipeline de inferencia y puntuación de riesgo

Serialicé todos los artefactos —el XGBoost calibrado, el Isolation Forest, el K-Means, los umbrales y el explicador SHAP— y construí el flujo de inferencia que convierte un usuario-día en una decisión accionable. La puntuación de riesgo (0–100) sigue la fórmula híbrida $\text{riesgo} = 100 \cdot (w \cdot p_{\text{sup}} + (1 - w) \cdot a_{\text{norm}})$, donde p_{sup} es la probabilidad calibrada y a_{norm} la anomalía normalizada. En lugar de adoptar un peso w arbitrario, lo elegí en validación por PR-AUC, y el resultado ($w = 0,95$) confirma con transparencia que el componente supervisado domina. Los niveles del semáforo los recalibré en el espacio 0–100 según la capacidad operativa del SOC.

9.2 Consumo de modelos: la API

Expuse los modelos mediante una API construida con FastAPI, que sirve una instantánea precomputada del periodo de prueba a través de ocho *endpoints* tipados: los indicadores generales, la cola de triaje priorizada, la serie temporal de riesgo por usuario, la explicación SHAP con comparativas, el resumen de actividad, el registro de decisiones del analista y un *endpoint* de inferencia en vivo. La API es la dueña de todo el conocimiento del modelo; el contrato queda documentado automáticamente mediante OpenAPI, y validé su comportamiento con una suite de 23 pruebas de contrato.

9.3 La interfaz de usuario

Desarrollé la interfaz con React (mediante Vite y TypeScript), desplegada en producción, con tres vistas que atienden a los tres perfiles de usuario: una **consola de triaje** con la cola priorizada, la evolución del riesgo y la explicación SHAP; una vista de **investigación** que incluye el mini-grafo ego que hace visible el movimiento lateral y el historial de decisiones; y un **panel ejecutivo** con la tendencia de riesgo por rol conductual y la eficiencia del SOC. Un principio gobernó todo el frontend: la interfaz nunca recalcula el riesgo; si un número no proviene de la API, no existe.

9.4 Asistente conversacional

Como componente adicional de usabilidad, integré un asistente conversacional que responde preguntas del usuario en lenguaje natural y sirve de guía. Lo implementé con la técnica de *function calling*: el modelo de lenguaje, cuando necesita un dato, invoca herramientas que consultan la instantánea real del modelo, de modo que responde con las cifras verdaderas del periodo en lugar de inventarlas. Por seguridad, la clave de la API del proveedor reside exclusivamente en el servidor y nunca se expone al navegador.

10. Conclusiones

Este proyecto me permitió recorrer el ciclo completo de un problema de ciencia de datos aplicado a un dominio real y difícil, desde mil millones de eventos crudos hasta una interfaz funcional en producción. Organizo las conclusiones en tres planos: los hallazgos del análisis, el impacto para la toma de decisiones y la justificación de las decisiones metodológicas de fondo.

10.1 Hallazgos sobre el problema

El hallazgo que considero más relevante, y que atraviesa todo el trabajo, es que la señal del uso indebido de credenciales vive en la **desviación** y en la **novedad de conexiones**, no en el volumen de actividad. El análisis SHAP lo confirmó de manera independiente: las variables dominantes son el protocolo anómalo y las máquinas nuevas, no cuántos eventos genera el usuario. El caso que analicé en detalle lo resume con precisión: el día del ataque, el volumen de esa cuenta estaba dentro de lo normal (0.69 desviaciones estándar respecto a su propia media) mientras su alcance estaba a 7.7 desviaciones. Un detector basado en volumen no habría visto nada.

Este resultado valida el diseño multinivel de la ingeniería de variables y, sobre todo, valida la premisa de negocio: un sistema que vigile umbrales absolutos de actividad fracasará frente a un atacante que opera dentro de una cuenta legítima.

10.2 Hallazgos sobre los datos

Tres resultados empíricos que no anticipaba al comenzar y que documento porque cambiaron decisiones concretas del proyecto:

1. **El ritmo humano de la red puede recuperarse de tiempos completamente anónimos.** Únicamente a partir de la periodicidad de los datos inferí el horario laboral (7:00–16:00) y los fines de semana, sin ningún calendario ex-

terno. Un matiz metodológico importante: existe una base de automatización 24/7 corriendo bajo cuentas de usuario, de modo que el umbral correcto es el punto medio entre valle y pico; usar un porcentaje del pico habría clasificado el día entero como laboral.

2. **El compromiso no se parece a la fuerza bruta.** Los días comprometidos presentan fallos con más frecuencia (50 % de los días frente a 24 %) pero en proporción mínima (ratio típico de 0.003), porque quien usa credenciales válidas robadas avanza con éxito. El fallo masivo pertenece a la población normal: el 17 % de los usuario-días normales son 100 % fallos, la firma de automatización con credenciales caducas. A nivel de evento, el *red team* autenticó con éxito el 99.9 % de las veces. Esta observación invirtió mi expectativa inicial y obligó a contextualizar la variable de fallos contra el historial del propio usuario en lugar de usarla en crudo.
3. **La variable de identidad destino resultó de las más discriminantes.** El número de veces que una cuenta aparece como identidad *destino* de otra —que añadí casi por completitud— separa las clases con una mediana de 20 frente a 0. Es la firma de las cadenas de saltos entre máquinas.

10.3 Impacto para la toma de decisiones

El valor del sistema no reside en una métrica sino en la curva que traduce el modelo a capacidad operativa. La Tabla 8 resume esa traducción.

Presupuesto de alertas diarias	Cobertura de cuentas comprometidas
20 alertas / día	31 %
30 alertas / día	38 %
50 alertas / día	38 %
100 alertas / día	85 %

Cuadro 8: Traducción del desempeño estadístico a capacidad operativa. Permite a un responsable de seguridad elegir su punto de operación en función del equipo disponible.

Esta tabla convierte una pregunta técnica —«¿qué tan bueno es el modelo?»— en una que una dirección puede responder: «**¿cuántos analistas cuesta cada punto de cobertura?»**. En lugar de imponer un umbral, el sistema permite elegir el punto de operación según los recursos reales.

También es necesario ser explícito sobre el costo. Al umbral naranja la precisión es baja: 13 aciertos frente a 280 falsos positivos. Presentado de forma aislada el dato suena descalificador, pero el marco correcto es otro: el sistema reduce 17 501 usuario-días a 212 casos revisables, y dentro de esa lista corta el analista descarta con rapidez

gracias al semáforo y la explicación. Es una herramienta de **priorización**, no de bloqueo automático, y por eso ninguna acción sobre una cuenta ocurre sin decisión humana.

Conviene subrayar además el encaje del producto: Nexus Sentinel no compite con el SIEM ni con el EDR, sino que consume sus registros y devuelve priorización explicada. Es exactamente la capa que faltaba en incidentes como el de Target, donde las alertas técnicas existían pero se perdieron entre el ruido porque nadie podía distinguir cuáles merecían atención.

10.4 Justificación del enfoque supervisado

La elección del aprendizaje supervisado como componente central está sólidamente justificada para este problema. Dado que dispongo de etiquetas verificadas del *red team*, puedo optimizar directamente la función objetivo del negocio y medir el desempeño de forma objetiva, algo que un enfoque puramente no supervisado —que solo identificaría desviaciones estadísticas sin distinguir compromiso genuino de comportamiento legítimo atípico— no permitiría.

No obstante, integré ambos paradigmas y ambos aportaron. El Isolation Forest actúa como línea base que contextualiza el desempeño del modelo central, y el agrupamiento de pares cumple un doble papel: genera las variables de desviación grupal —que resultaron valiosas en el análisis SHAP— y, como puntuación de anomalía por distancia al centroide, superó a la línea base con un modelo mucho más simple (PR-AUC de 0.093 frente a 0.027).

10.5 Sobre el rigor metodológico

Valoro especialmente que los conflictos que enfrenté —el *data fence* en la adquisición, el agrupamiento degenerado y, sobre todo, la autocorrección de la fuga metodológica— no fueran obstáculos que ocultar, sino oportunidades para demostrar el rigor con el que abordé el trabajo.

Si tuviera que quedarme con una sola idea del proyecto, sería que **la honestidad metodológica es parte del resultado**. Documenté el agrupamiento que tuve que corregir, la fuga que yo mismo introduje y detecté, las tres palancas de mejora que no funcionaron y la tasa de falsos positivos sin filtrar. Un modelo con métricas modestas pero verificables y estables vale más que uno con números vistosos que no resistirían escrutinio; y en seguridad, donde las decisiones afectan a personas, esa diferencia es la que importa.

11. Limitaciones y recomendaciones

11.1 Limitaciones del trabajo

Prefiero enunciarlas explícitamente antes que dejar que las descubra quien evalúe el proyecto:

- **El volumen de positivos marca el techo.** Con 181 eventos de compromiso en todo el conjunto (120, 27 y 34 por partición), el margen estadístico es estrecho. Probé tres palancas de mejora y ninguna sobrevivió a una selección honesta en validación.
- **Dos variables derivan entre campañas.** Las desviaciones de fallos y de NTLM respecto a los pares presentan un índice de estabilidad alto, porque dependen de *cómo* ataca el equipo ofensivo en cada campaña. La puntuación agregada se mantiene estable, pero esas dos variables requerirían monitoreo en un despliegue real.
- **La fuente tiene un sesgo conocido.** El conjunto solo incluye fallos de autenticación de usuarios que tuvieron al menos un éxito, de modo que los ataques de adivinación contra cuentas inexistentes quedan fuera del alcance por construcción. No es corregible: son registros que no existen.
- **El ROC-AUC de 0.939 es engañoso** con este desbalance, razón por la cual lo reporto siempre acompañado de la curva de precisión-recall.
- **La inferencia opera sobre variables precomputadas**, no sobre eventos crudos en caliente. La reconstrucción completa desde eventos reutilizaría los mismos módulos, pero requeriría transmitir el estado histórico de cada usuario.

11.2 Recomendaciones y trabajo futuro

Ordeno las líneas de continuación por la relación entre impacto esperado y esfuerzo requerido:

1. **Enriquecer con fuentes de datos adicionales.** Es la única palanca que añadiría *señal nueva* en lugar de reordenar la existente, y por eso la sitúo en primer lugar. El propio conjunto de LANL incluye eventos de procesos y flujos de red que no utilicé. Un proceso inusual ejecutándose en una máquina recién alcanzada constituye evidencia independiente del movimiento lateral, y combinarla con la novedad de grafo debería mejorar la precisión justamente donde más importa: en la cabeza de la cola de triaje.

2. **Cerrar el ciclo de retroalimentación.** La interfaz ya registra las decisiones del analista (falso positivo, investigar, escalar). Con suficientes decisiones acumuladas, esas etiquetas humanas permitirían reentrenar el modelo sobre lo que el equipo considera realmente relevante, que no siempre coincide con la definición del *red team*.
3. **Recalibrar los umbrales periódicamente.** Observé que el volumen de alertas se desplaza ligeramente entre periodos. En operación, los percentiles deberían recalcularse sobre una ventana móvil reciente en lugar de quedar fijos, de modo que la carga diaria se mantenga dentro de la capacidad del equipo.
4. **Convertir el análisis de estabilidad en monitoreo continuo.** Los índices PSI y CSI que calculé no deberían ser un ejercicio único: automatizados, permitirían detectar cuándo el modelo necesita reentrenarse porque el comportamiento de la red cambió.
5. **Explorar modelos de secuencia.** La unidad usuario-día resume una jornada completa en una fila. Modelos que traten la secuencia de eventos dentro del día podrían capturar el *orden* del movimiento lateral, no solo su magnitud. Lo sitúo al final deliberadamente: con 181 positivos, un modelo de mayor capacidad probablemente sobreajustaría, de modo que esta línea solo tiene sentido después de ejecutar la primera.

12. Referencias

- [1] Verizon. (2024). *2024 Data Breach Investigations Report (DBIR)*. Verizon Business. <https://www.verizon.com/business/resources/reports/dbir/>
- [2] Kent, A. D. (2015). *Comprehensive, Multi-Source Cyber-Security Events* [Data set]. Los Alamos National Laboratory. <https://csr.lanl.gov/data/cyber1/>
- [3] Kent, A. D. (2015). Cybersecurity Data Sources for Dynamic Network Research. En *Dynamic Networks and Cyber-Security*. Imperial College Press.
- [4] Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation Forest. *Proceedings of the 2008 Eighth IEEE International Conference on Data Mining (ICDM)*, 413–422.
- [5] Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794.

- [6] Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *Advances in Neural Information Processing Systems (NeurIPS)*, 30, 4765–4774.
- [7] MacQueen, J. (1967). Some Methods for Classification and Analysis of Multivariate Observations. *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, 1, 281–297.
- [8] Rousseeuw, P. J. (1987). Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis. *Journal of Computational and Applied Mathematics*, 20, 53–65.
- [9] Saito, T., & Rehmsmeier, M. (2015). The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. *PLoS ONE*, 10(3), e0118432.
- [10] Siddiqi, N. (2006). *Credit Risk Scorecards: Developing and Implementing Intelligent Credit Scoring*. John Wiley & Sons. (Referencia para los índices de estabilidad PSI, CSI y el estadístico KS.)
- [11] The MITRE Corporation. (2023). *MITRE ATT&CK: Lateral Movement (TA0008) y Use Alternate Authentication Material: Pass the Hash (T1550.002)*. <https://attack.mitre.org/>